

# QML con Angle Embedding y DNN para b-Tagging en Jets de Bajo Momento

## Comparación de técnicas cuánticas y clásicas en el régimen de bajo $p_T$

Juan Montoya

Instituto de Física  
Universidad de Antioquia

2 de octubre de 2025

## Estructura de la Presentación

# Introducción

# Quantum Machine Learning

## Arquitectura del Circuito

## Metodología

## Resultados

## Conclusiones

## Referencias

# ¿Qué son los Jets?

## Definición

- Chorros colimados de partículas
- Producidos en hadronización

## Desafío del b-tagging

- Identificar jets de quarks b
- Problemas con jets de  $p_T$  menor a 20 GeV





Figura: Estructura típica de un jet

# El reto del bajo momento


## Régimen de $p_T < 20$ GeV

- Alta densidad de partículas
- Baja resolución de trazas



## Importancia

- Acceso a nueva física
- Nuevas metodologías



**Figura:** Distribución de jets de bajo  $p_T$



**Figura:** Comparación con alto  $p_T$



# Comparativa visual: alto vs bajo $p_T$

## Diferencias

- Estructura interna
- Calidad de reconstrucción



**Figura:** Izquierda: Jet de bajo  $p_T$  ( $< 20$  GeV). Derecha: Jet de alto  $p_T$  ( $> 20$  GeV)

# Motivación para QML

## ¿Por qué QML?

- Potencial para correlaciones complejas
- Exploración eficiente de espacios de alta dimensión




Figura: Ventaja potencial de QML

# Fundamentos de QML

## Características Clave

- Computación híbrida cuántico-clásica
- Circuitos variacionales parametrizados
- Optimización clásica de parámetros

## Ventajas Potenciales

- Superposición cuántica
- Entrelazamiento de estados




Figura: Esquema QML

# Angle Embedding: Concepto

## Fundamentos

Para un vector de características

$$\mathbf{x} = [x_1, \dots, x_n]:$$

- Normalización en  $[-\pi, \pi]$
- Un qubit por característica
- Rotaciones  $RX(x_i)$  o  $RY(x_i)$




Figura: Representación en esfera de Bloch



# Aplicación al b-tagging

## 16 Características del Jet

- Variables cinemáticas ( $p_T$ ,  $\eta$ ,  $\phi$ )
- Multiplicidad de partículas

## Codificación Cuántica

$$|\psi\rangle = \bigotimes_{i=1}^{16} R_Y(x_i)|0\rangle$$

donde  $x_i$  son las características normalizadas




Figura: Circuito cuántico con Angle Embedding

# Diseño del Circuito QML

## Componentes Principales

- device: **lightning.gpu** (simulador)
- 16 qubits para características del jet
- 4 capas de entrelazamiento
- Medición del observable  $\langle Z_0 \rangle$

## Implementación

- Framework: PennyLane + PyTorch
- Optimizador: Adam ( $lr = 0,02$ )




Figura: Estructura del circuito

# Capas de entrelazamiento fuerte

## Estructura por capa

### 1. Rotaciones locales

- $RX(\theta)$ ,  $RY(\phi)$ ,  $RZ(\lambda)$
- Parámetros entrenables

### 2. Entrelazamiento

- Puertas CNOT y CZ




Figura: Estructura del circuito

# ¿Dónde está el Aprendizaje?

## Angle Embedding (Fijo )

- Codifica las 16 features del jet
- Solo depende de los datos de entrada

$$|\psi\rangle = \bigotimes_i R_Y(\theta_i^{\text{jet}})|0\rangle$$

## Capas Variacionales (Entrenable )

### 192 parámetros optimizados

- 4 capas de rotaciones  
 $R(\alpha, \beta, \gamma)$
- 16 qubits  $\times$  3 ángulos = 48 parámetros/capa

$$U(\vec{w}) = \prod_{l=1}^4 \left[ \prod_i R_i^l(\vec{w}_i^l) \cdot \text{CNOT} \right]$$

$$\hat{y} = \langle 0 | U^\dagger(\vec{w}) \cdot \sigma_z \cdot U(\vec{w}) | \psi_{\text{data}} \rangle$$

↑ Aquí se optimiza  $\vec{w}$  para minimizar el error

# Correlaciones cuánticas en el circuito

## Observables de medición

$$\langle Z_0 \rangle = \langle \psi | Z_0 | \psi \rangle \in [-1, 1]$$

- +1: b-jet
- -1: anti-b-jet




Figura: Estructura del circuito

# Flujo de trabajo

## Preprocesamiento

1. Carga de histogramas ROOT
2. Normalización con arctan
3. Selección de 16 características

## Modelos

- **QML**: 16 qubits, 4 capas SEL
- **DNN**: 16-64-32-1, ReLU/tanh

## Entrenamiento

- Optimizador: Adam
- Learning rate: 0.02
- Épocas: 10

## Evaluación

- AUC-ROC
- Tagging Power
- Análisis por  $p_T$

# Comparación de rendimiento

## Datasets analizados

- Zbb\_LowPT ( $p_T < 20$  GeV)
- Zbb\_HighPT ( $p_T \geq 20$  GeV)
- Zp\_M30\_LowPT
- Zp\_M100\_LowPT



Figura: Comparativa AUC

## Métricas clave

- AUC: QML vs DNN
- Tagging Power ( $\epsilon_{\text{tag}}$ )

# Análisis por régimen de $p_T$

## Observaciones

- DNN superior en alto  $p_T$
- Brecha menor en bajo  $p_T$
- Potencial para mejora en QML
- Consideración del tamaño muestral

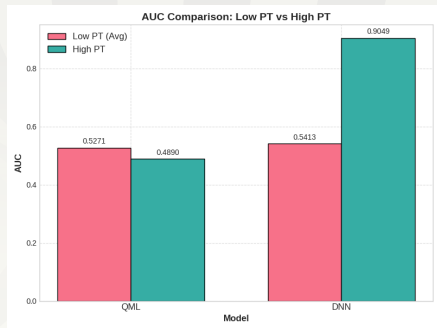


Figura: Rendimiento en función del  $p_T$



# Tagging power

$$\epsilon_{\text{tag}} = \epsilon_{\text{eff}}(2a - 1)^2$$

- $\epsilon_{\text{eff}}$ : eficiencia de tagging

## Resultados

- $Z'$ : desafío para ambos




Figura: Tagging Power por dataset

# Hallazgos principales

## Observaciones

- Mayor variabilidad en bajo  $p_T$
- Potencial para mejora

## Desafíos

- Muestra limitada (1000 eventos)
- El regimen de baja energia del Z'




Figura: Resumen de rendimiento

# Perspectivas futuras

## Mejoras técnicas

- Arquitecturas más profundas
- Embeddings alternativos
- Optimización de hiperparámetros

## Nuevas direcciones

- Variables específicas para QML
- Análisis de correlaciones cuánticas
- Hardware

## Impacto potencial

- Mejor discriminación en bajo  $p_T$
- Acceso a nueva física

# Referencias y recursos

## Artículos principales



A. Gianelle et al., "First implementation of QML for b-jet tagging at LHCb", 2021. [Presentación](#)



A. Gianelle et al., "QML for b-jet charge identification", 2022.

[Artículo](#)



"Quantum Neural Networks explained", 2024. [Video Tutorial](#)

## Código

Repositorio disponible en GitHub:  
[github.com/JuanJ27/LowPt-Jet-Qml](https://github.com/JuanJ27/LowPt-Jet-Qml)